

Analyse Sémantique Multilingue par Transformers Pré-entraînés

Prof. Ahmed Benali, Laboratoire de Linguistique Computationnelle
IA-Technology Research Center — Avril 2025

Résumé

Ce travail présente un modèle Transformer multilingue fine-tuné pour la compréhension sémantique dans cinq langues (français, anglais, arabe, espagnol, allemand). En utilisant une architecture encoder-decoder avec attention croisée entre langues, notre modèle MultiSem-T5 atteint un score F1 de 89.4% sur le benchmark XNLI.

1. Introduction

Le traitement automatique du langage naturel (TALN) multilingue est devenu un enjeu crucial avec la mondialisation des systèmes d'information. Les modèles pré-entraînés monolingues atteignent des performances remarquables, mais leur adaptation aux contextes multilingues reste problématique.

2. Architecture du Modèle

MultiSem-T5 repose sur une architecture T5 modifiée avec trois innovations : (1) un tokenizer unifié couvrant 100 000 sous-mots partagés entre les cinq langues, (2) des couches d'attention spécifiques à chaque langue, et (3) un mécanisme d'alignement sémantique dans les couches supérieures.

3. Expériences

Le modèle est pré-entraîné sur un corpus de 120 Go de texte. Sur XNLI, nous observons un score F1 de 89.4% en moyenne, avec des performances particulièrement fortes en français (91.2%) et en arabe (87.8%).

4. Conclusion

MultiSem-T5 démontre qu'une architecture avec alignement sémantique explicite surpasse les approches multilingues génériques. Le transfert cross-lingual est significativement amélioré.

Références

- [1] Devlin, J. et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers. NAACL.
- [2] Conneau, A. et al. (2020). Unsupervised Cross-lingual Representation Learning. ACL.
- [3] Raffel, C. et al. (2020). Exploring the Limits of Transfer Learning with T5. JMLR.