

Détection d'Objets en Temps Réel par Vision Transformer Légère

Dr. Marie Laurent & Dr. Karim Hosseini

Laboratoire de Vision par Ordinateur, IA-Technology — Mars 2025

Résumé

Nous proposons LiteViDet, un modèle de détection d'objets en temps réel basé sur une architecture Vision Transformer allégée. En réduisant le nombre de paramètres de 78% par rapport à DETR tout en maintenant 96% de sa précision, LiteViDet atteint 42 FPS sur un GPU mobile.

1. Introduction

La détection d'objets en temps réel est essentielle pour les applications embarquées : véhicules autonomes, drones de surveillance, robotique industrielle. Les modèles actuels comme YOLOv8 sont efficaces mais limités en contexte dense.

2. Architecture LiteViDet

LiteViDet combine un backbone EfficientNet-B0 pour l'extraction de features locales avec un module Transformer allégé de 4 couches. L'attention sparse réduit la complexité de $O(n^2)$ à $O(n \cdot \log(n))$ en ne calculant l'attention que sur les patches les plus informatifs.

3. Résultats

Sur COCO val2017, LiteViDet atteint un mAP de 41.3% avec seulement 12M de paramètres, contre 41.0% pour DETR (41M paramètres). En vitesse, LiteViDet traite 42 images par seconde sur Jetson Orin Nano, contre 8 FPS pour DETR.

4. Applications

Nous démontrons l'applicabilité sur trois cas : (1) comptage de piétons en temps réel avec une précision de 94.7%, (2) inspection de défauts sur ligne de production avec 98.2% de détection, et (3) navigation de drone avec évitement d'obstacles à 30 Hz.

5. Conclusion

LiteViDet prouve que les Vision Transformers peuvent être déployés efficacement sur du matériel embarqué sans compromis majeur sur la précision.

Références

- [1] Carion, N. et al. (2020). End-to-End Object Detection with Transformers. ECCV.
- [2] Dosovitskiy, A. et al. (2021). An Image is Worth 16x16 Words. ICLR.

[3] Ultralytics (2023). YOLOv8: State-of-the-Art Real-Time Object Detection.